Modélisation d'une éolienne, modélisation des incertitudes

C. Helbert et E. Mironescu

23 novembre 2021

UNIVERSITÉ DE LYON

ÉCOLE CENTRALE LYON

Modèle - validation de modèle

Modélisation des incertitudes

Propagation des incertitudes

Extensions

Notion de modèle

- Expérience physique complexe (réalité) : le vent entraine une production électrique

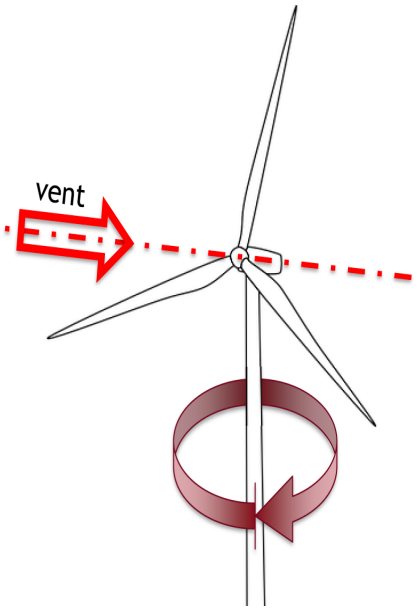

- modélisation (approximation de la réalité) : proposer un **modèle mathématique** qui représente au mieux la réalité physique

Notion de modèle

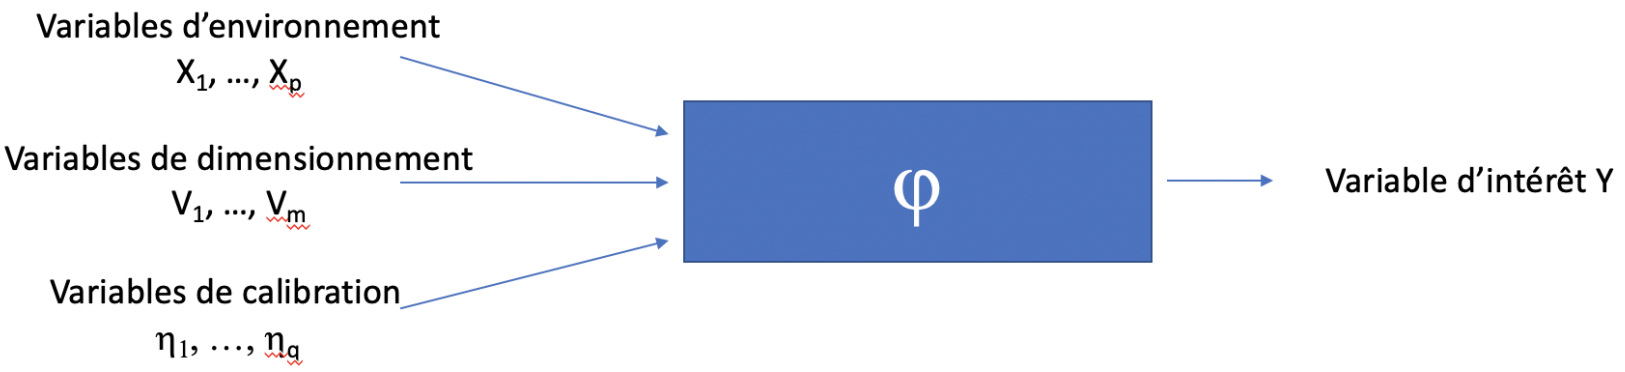

- Différentes possibilités pour φ
  - Formule explicite
  - Equations différentielles
- Souvent on ajoute une étape **d'approximation numérique** de φ. Des variables supplémentaires interviennent pour caractériser le schéma numérique (ex : finesse de la discrétisation spatiale, temporelle etc.).

Exemple de l'éolienne

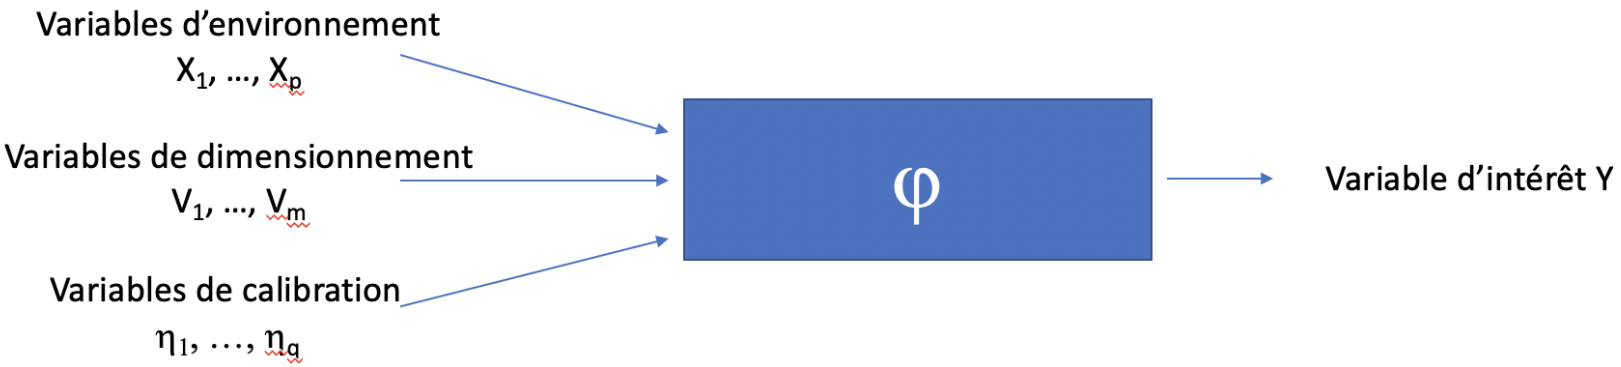

- Y : Production électrique
- φ : formule explicite
- $X_1, \ldots, X_p$: direction vent, vitesse du vent, la masse volumique de l'air
- $V_1, \ldots, V_m$: diamètre de l'éolienne
- $\eta_1, \ldots, \eta_q$: le rendement de l'éolienne

Le modèle en pratique

- Calibration : à partir d'observations de la réalité on "calibre" les variables de calibration (coefficients des équations).
- Validation : une fois calibré, le modèle convient-il à la réalité ?
- Propagation d'incertitudes : si $\mathbf{X} \sim \mu_\theta$ alors $Y \sim$?
- Problématique de dimensionnement : choix de $\mathbf{V}$ de sorte à optimiser la variable d'intérêt Y.

=> beaucoup plus simple de répondre aux deux dernières questions sur le modèle qu'à partir d'expériences de la réalité.

La calibration du modèle en fonction des observations

On se fixe les variables de dimensionnement $\mathbf{V} = \mathbf{v}_0$ (exemple : diamètre de l'éolienne $D = D_0$) et on souhaite ajuster le modèle à la réalité en jouant sur les paramètres de calibration.

On dispose d'un échantillon $\mathbf{x}^{(1)}, ..., \mathbf{x}^{(n)} \in \mathbb{R}^p$ sur lequel des observations $y^{(1)}, ..., y^{(n)}$ ont été collectées.
Trouver η tel que

$$\forall 1 \leq i \leq n, \varphi(\mathbf{x}^{(i)}, \mathbf{v}_0, \eta) \approx y^{(i)}$$

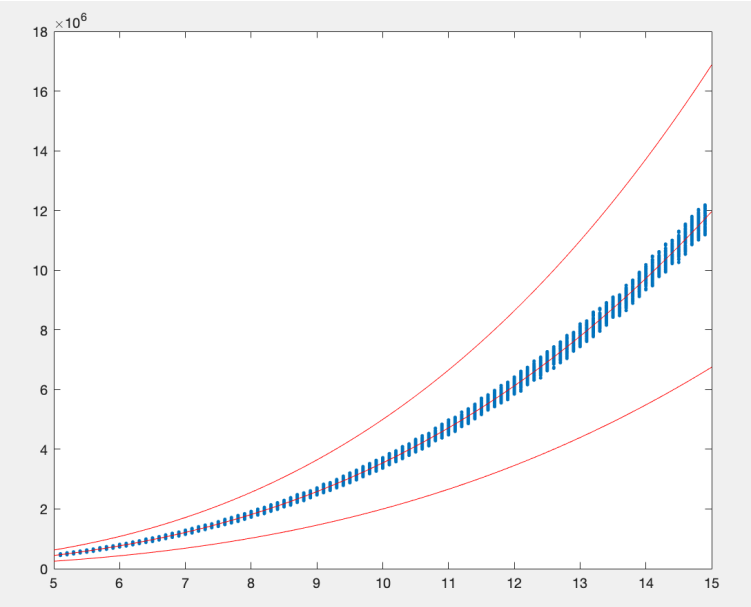

En rouge : le modèle.En bleu : les observations.

Le critère des moindres carrés

Objectif : trouver η qui minimise $\mathcal{C}(\eta)$ où

$$\mathcal{C}(\eta) = \sum_{i=1}^{n} \left(y^{(i)} - \varphi(\mathbf{x}^{(i)}, \mathbf{v}_0, \eta) \right)^2$$

- Si φ est linéaire en η alors la solution $\hat{\eta}$ du problème est explicite.
- Sinon on met en place un algorithme numérique d'optimisation globale.

Exemple dans le cas linéaire

Supposons que $\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \in \mathbb{R}^2$, que $\eta = \begin{pmatrix} \eta_0 \\ \eta_1 \\ \eta_2 \end{pmatrix} \in \mathbb{R}^3$ et que $\varphi(\mathbf{x}, \eta) = \eta_0 + \eta_1 x_1 + \eta_2 x_2^3$. Le critère des moindres carrés s'écrit :

$$\mathcal{C}(\eta) = \sum_{i=1}^{n} \left(y^{(i)} - \varphi(\mathbf{x}^{(i)}, \eta) \right)^2 = \|\mathbf{y} - \mathbb{X}\eta\|^2$$

où $\mathbb{X} = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)^3} \\ .. & .. & .. \\ 1 & x_1^{(i)} & x_2^{(i)^3} \\ .. & .. & .. \\ 1 & x_1^{(n)} & x_2^{(n)^3} \end{bmatrix}$ et $\mathbf{y} = \begin{pmatrix} y^{(1)} \\ .. \\ y^{(i)} \\ .. \\ y^{(n)} \end{pmatrix}$.

La solution est alors

$$\hat{\eta} = \left(\mathbb{X}'\mathbb{X}\right)^{-1} \mathbb{X}'\mathbf{y}.$$

Notation : $\mathbb{X}'$ correspond à la transposée de la matrice $\mathbb{X}$.

Exemple dans le cas non linéaire

On peut souvent revenir au cas linéaire :

- $\varphi(x,\eta) = \eta_0 \mathbf{1}_{x \leq s_1} + \eta_1 x^3 \mathbf{1}_{s_1 \leq x \leq s_2} + \eta_2 \mathbf{1}_{x \geq s_2}$

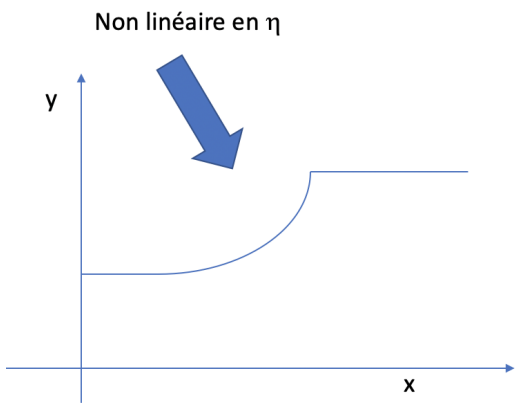

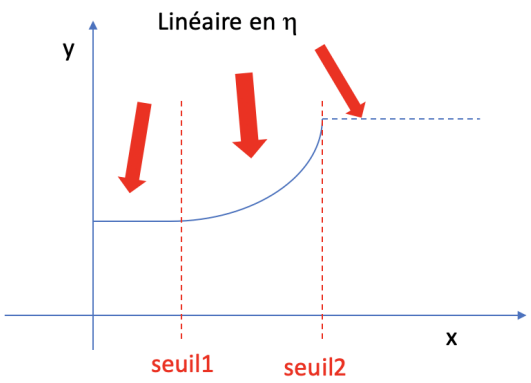

- $\varphi(x,\eta) = \eta_0 x^{\eta_1}$

  => on transforme en passant au log

Validation et exploitation du modèle

- Pour un dimensionnement de $\mathbf{v}_0$, grâce aux observations on a calibré le modèle $\varphi(\mathbf{x}, \mathbf{v}_0, \hat{\eta})$.
- Validation : Pour valider le modèle on considère un ensemble d'observations $\{\tilde{\mathbb{X}}, \tilde{\mathbf{y}}\}$ n'ayant pas servi pour la calibration (ensemble de test) et on compare l'erreur des moindres carrés sur l'ensemble d'apprentissage et l'erreur sur l'ensemble test.
- Prédiction : Une fois le modèle validé, on peut alors connaitre la valeur de la variable d'intérêt en un nouveau point $\mathbf{x}_0$ sans avoir recours à l'expérience, juste en évaluant $\varphi(\mathbf{x}_0, \mathbf{v}_0, \hat{\eta})$

Attention : Le modèle φ doit pouvoir être évalué sur tous les $\mathbf{x}$ possibles, la fonction Matlab ou python doit être écrite en ce sens.

Modèle - validation de modèle

Modélisation des incertitudes

Propagation des incertitudes

Extensions

Où sont les incertitudes ?

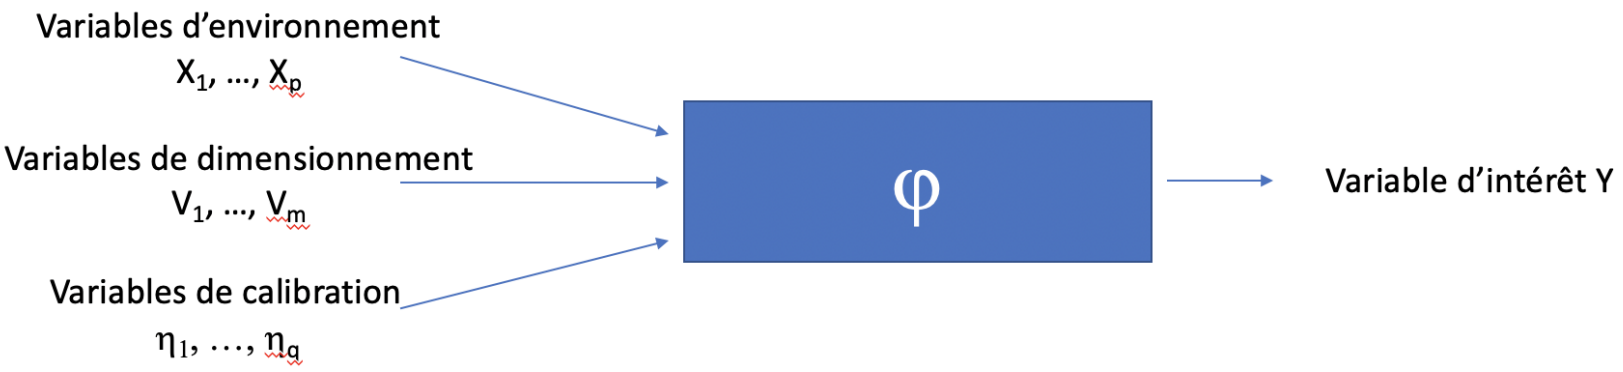

Où sont les incertitudes ?

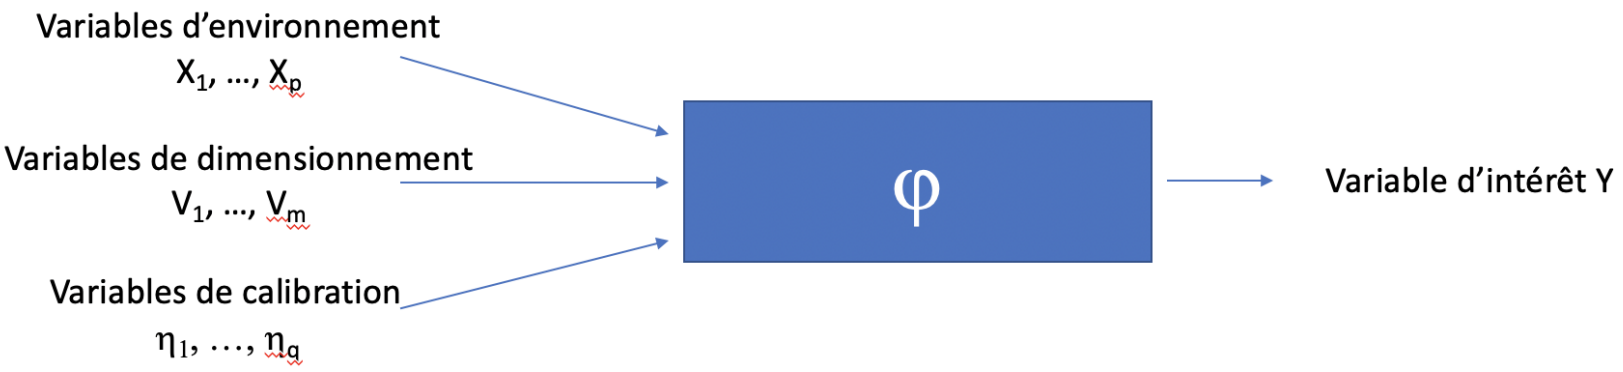

- Variables d'environnement

Où sont les incertitudes ?

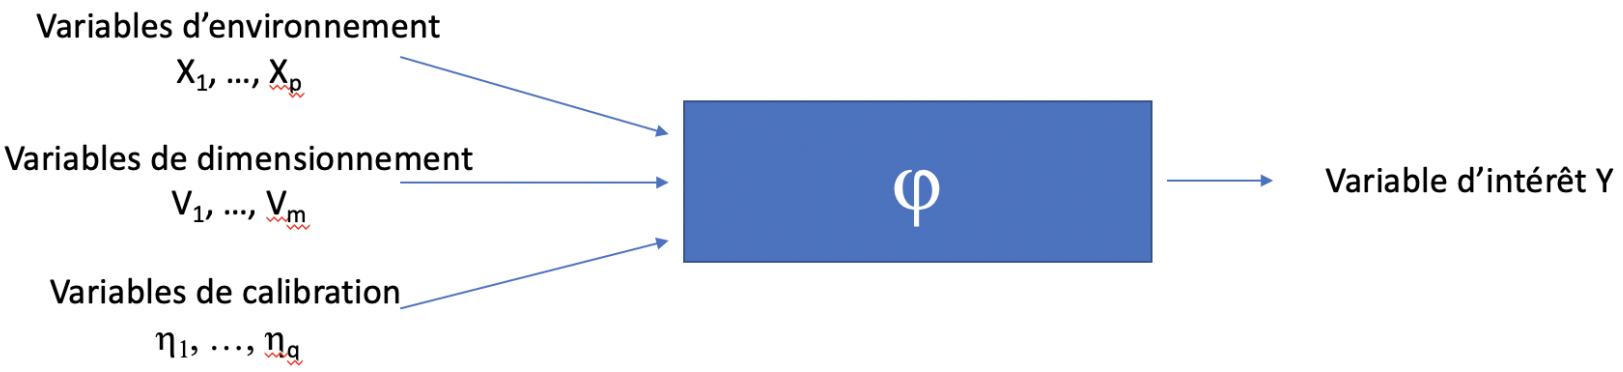

- Variables d'environnement
- Variables de calibration

Où sont les incertitudes ?

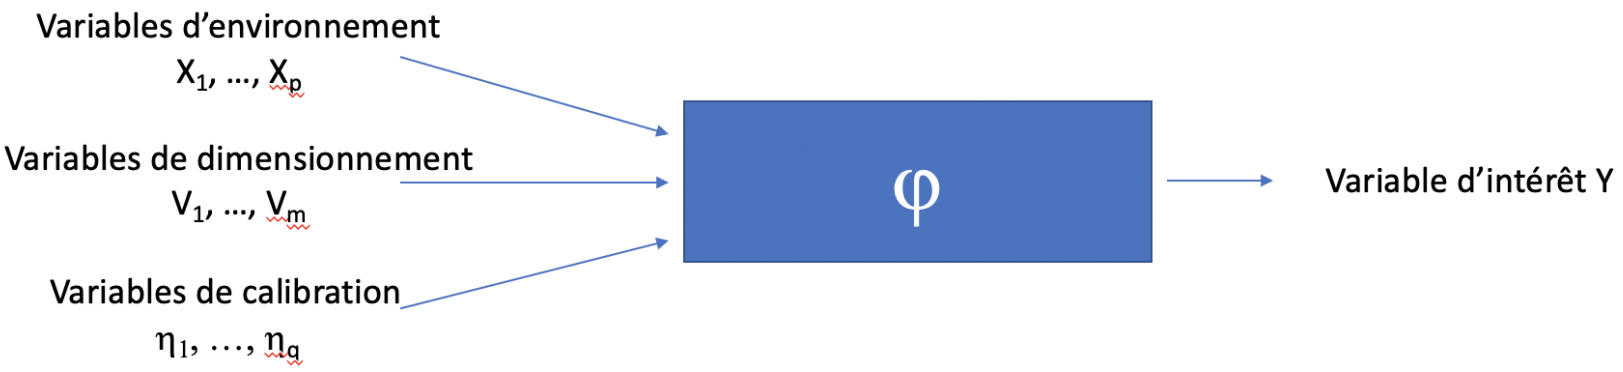

- Variables d'environnement
- Variables de calibration
- Le modèle φ

Où sont les incertitudes ?

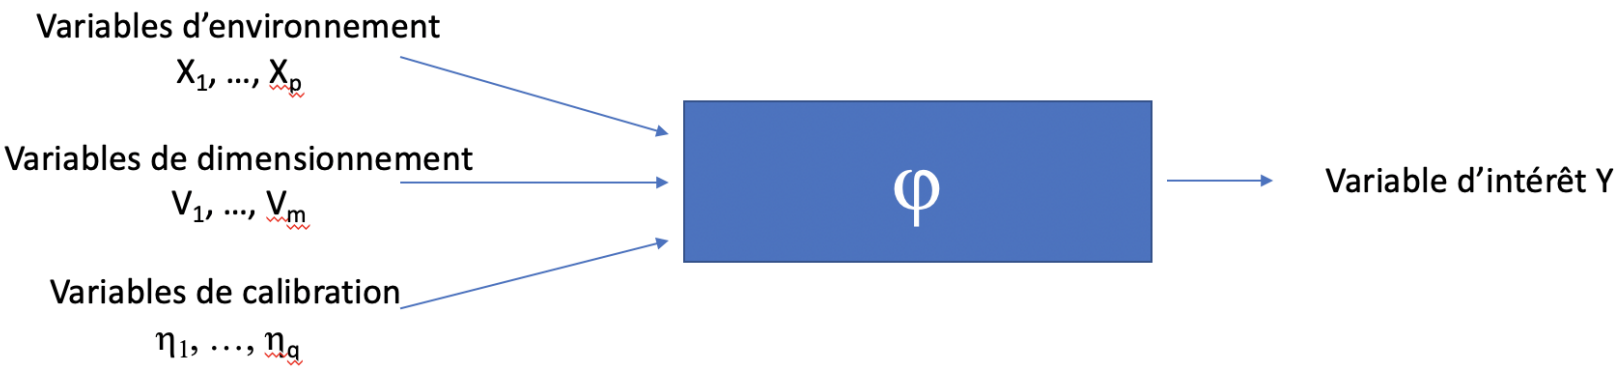

- **Variables d'environnement**
- Variables de calibration
- Le modèle φ

Statistique descriptive

Objectif : Donner des éléments visuels et quantitatifs qui permettent d'appréhender une distribution de probabilité à partir d'observations.

L'**histogramme** est une approximation de la densité par une fonction constante par morceaux.

Quelles sont les propriétés de cette fonction ?

Statistique descriptive

Objectif : Donner des éléments visuels et quantitatifs qui permettent d'appréhender une distribution de probabilité à partir d'observations.

L'**histogramme** est une approximation de la densité par une fonction constante par morceaux.

Quelles sont les propriétés de cette fonction ? positive, d'intégrale 1.

Les **résumés numériques** permettent de caractériser la position, la dispersion de la distribution etc.

L'histogramme

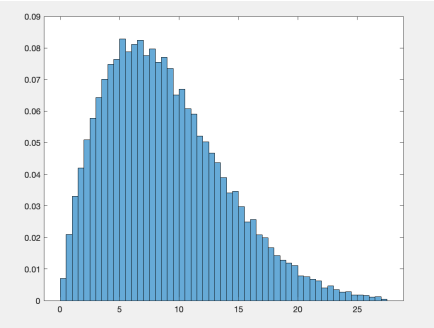

Classe	Effectifs	Proba	Densité
$[b_0, b_1]$	N_1		
...	...		
$[b_{J-1}, b_J]$	N_J		
	N		

L'histogramme

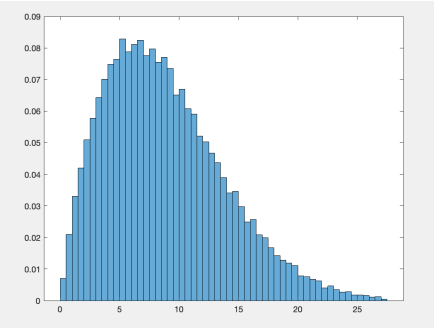

Classe	Effectifs	Proba	Densité
$[b_0, b_1]$	N_1	$\frac{N_1}{N}$	$\frac{N_1}{N}\frac{1}{b_1-b_0}$
...	...	...	...
$[b_{J-1}, b_J]$	N_J	$\frac{N_J}{N}$	$\frac{N_J}{N}\frac{1}{b_J-b_{J-1}}$
	N	1	

On peut alors visualiser :

- si la distribution est symétrique / asymétrique
- si la distribution est unimodale / multimodale

Comparaison des distributions

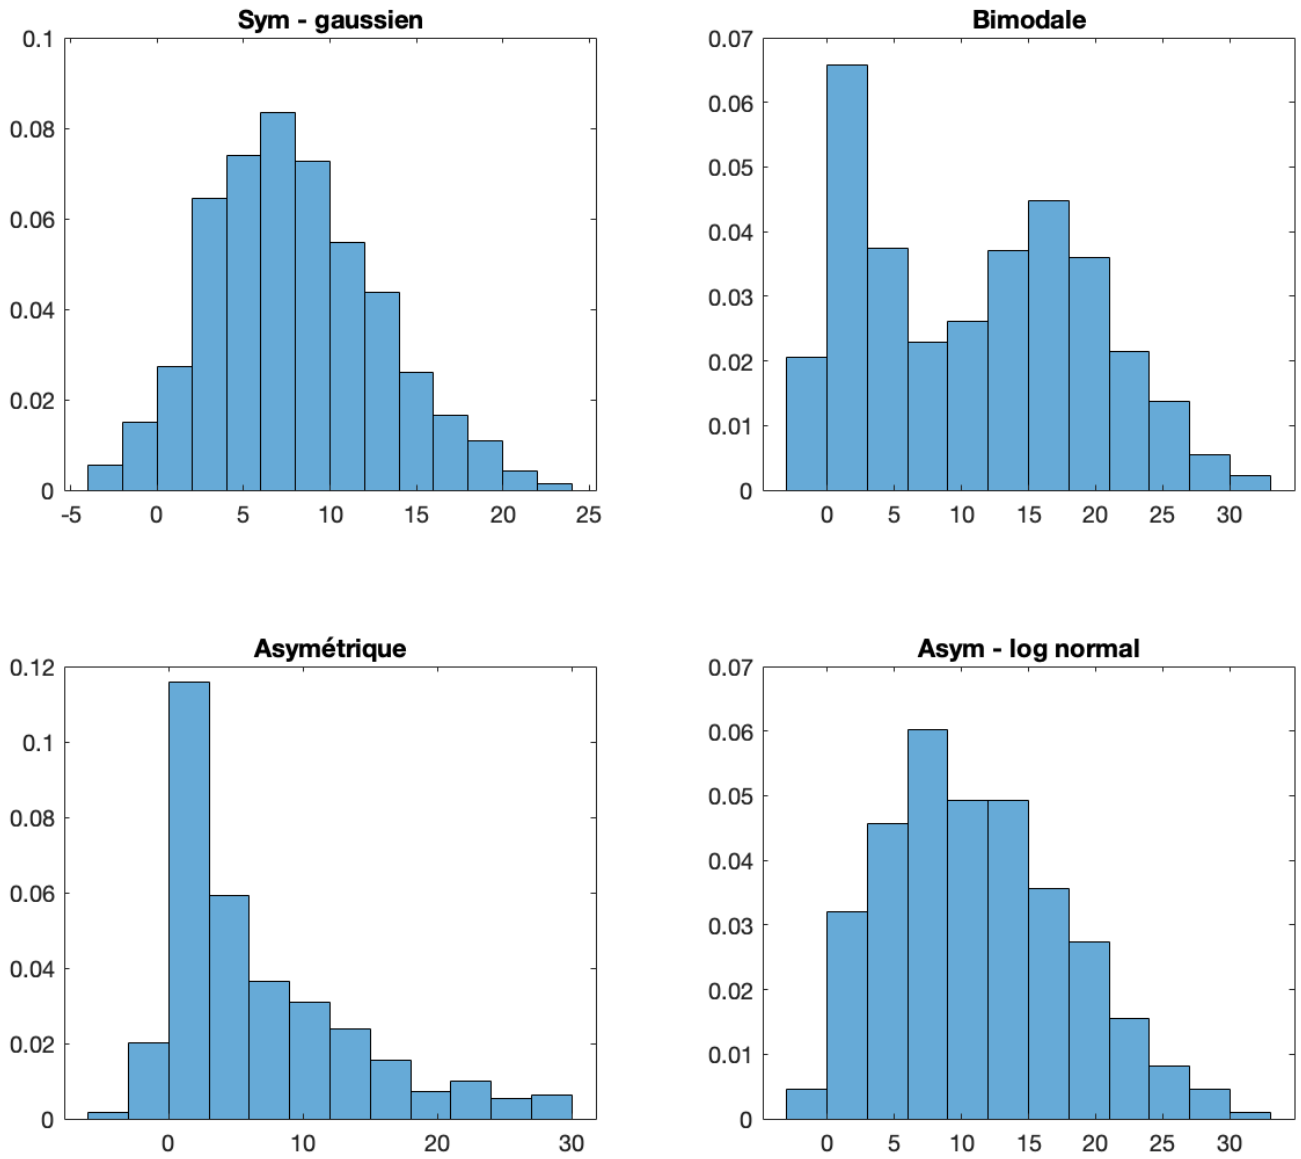

Comparaison des distributions

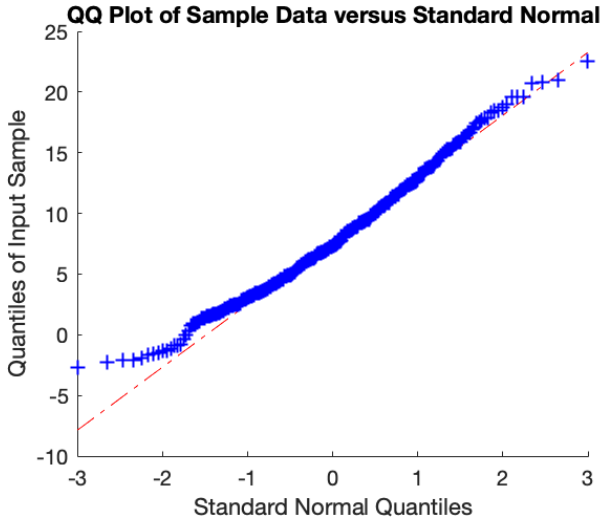

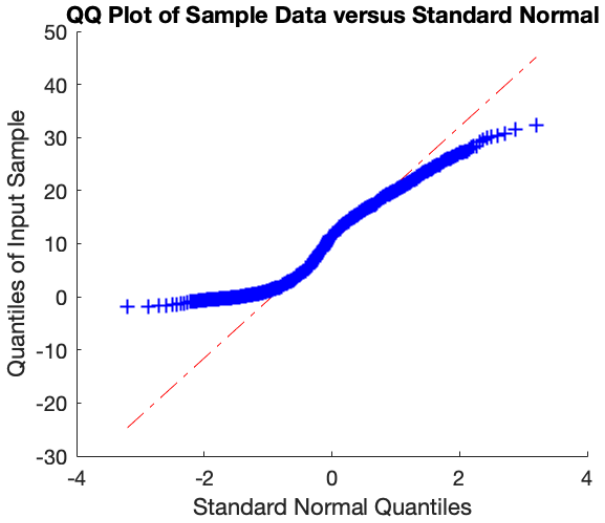

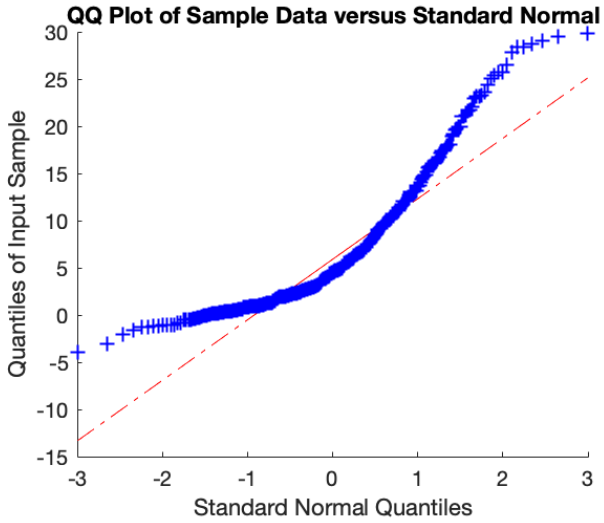

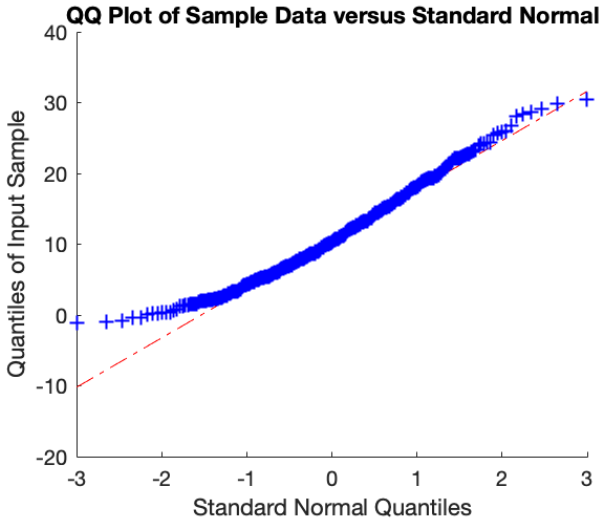

Comparaison des distributions

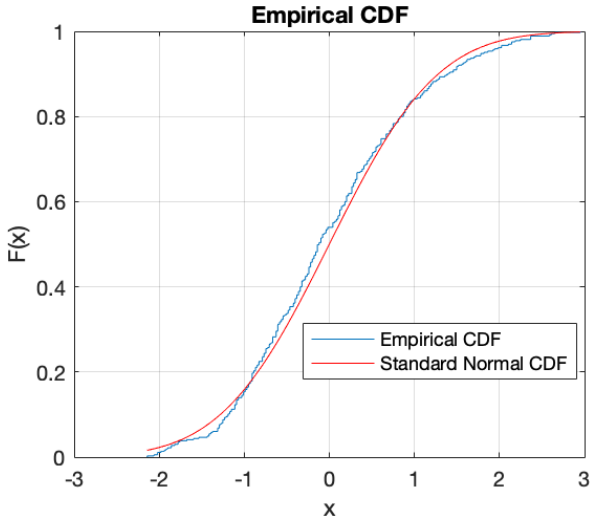

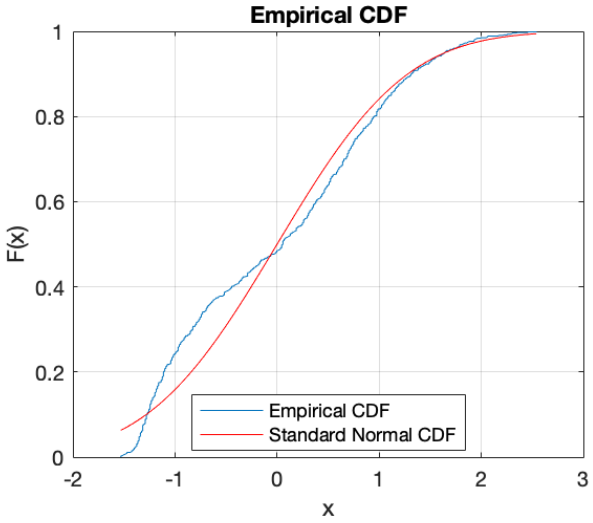

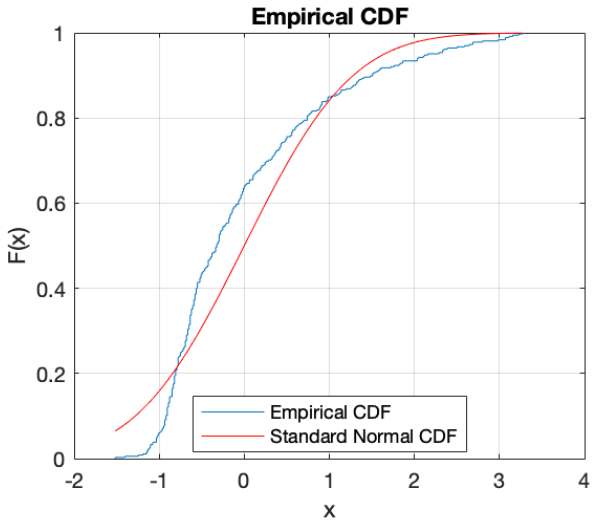

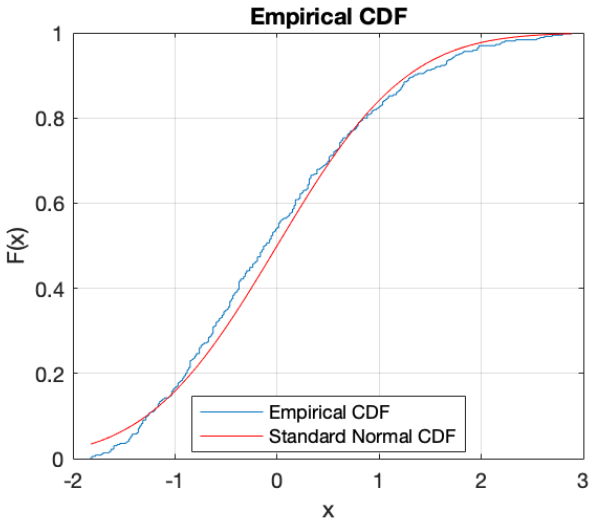

Résumés numériques

Distribution symétrique gaussienne :

Résumés numériques

Distribution symétrique gaussienne :

- indicateur de position : moyenne $\bar{x}$

Résumés numériques

Distribution symétrique gaussienne :

- indicateur de position : moyenne $\bar{x}$
- indicateur de dispersion : écart-type s

Résumés numériques

Distribution symétrique gaussienne :

- indicateur de position : moyenne $\bar{x}$
- indicateur de dispersion : écart-type s

Distribution multi-modale (mélange) :

Résumés numériques

Distribution symétrique gaussienne :

- indicateur de position : moyenne $\bar{x}$
- indicateur de dispersion : écart-type s

Distribution multi-modale (mélange) :

- modes (maxima locaux de la densité)
- probabilités de chaque sous-population dans le mélange

Distribution asymétrique :

Résumés numériques

Distribution symétrique gaussienne :

- indicateur de position : moyenne $\bar{x}$
- indicateur de dispersion : écart-type s

Distribution multi-modale (mélange) :

- modes (maxima locaux de la densité)
- probabilités de chaque sous-population dans le mélange

Distribution asymétrique :

- quantiles : médiane (50%), quartiles (25%, 75%), percentiles (2.5%, 97.5%)

Exemple - vitesse du vent

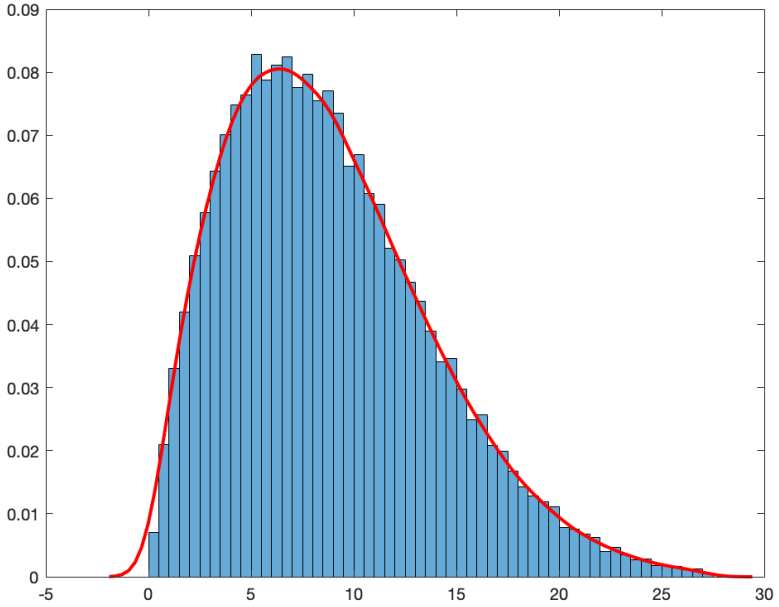

En rouge : estimation non paramétrique de la densité

- $\bar{x} = 8.8\ (ms^{-1})$, $s = 5\ (ms^{-1})$
- $q_{0.05} = 1.9$, $q_{0.25} = 5$, $q_{0.5} = 8.1$, $q_{0.75} = 11.8$, $q_{0.95} = 18.1$
- mode $= 6.4\ (ms^{-1})$

Exemple - direction du vent

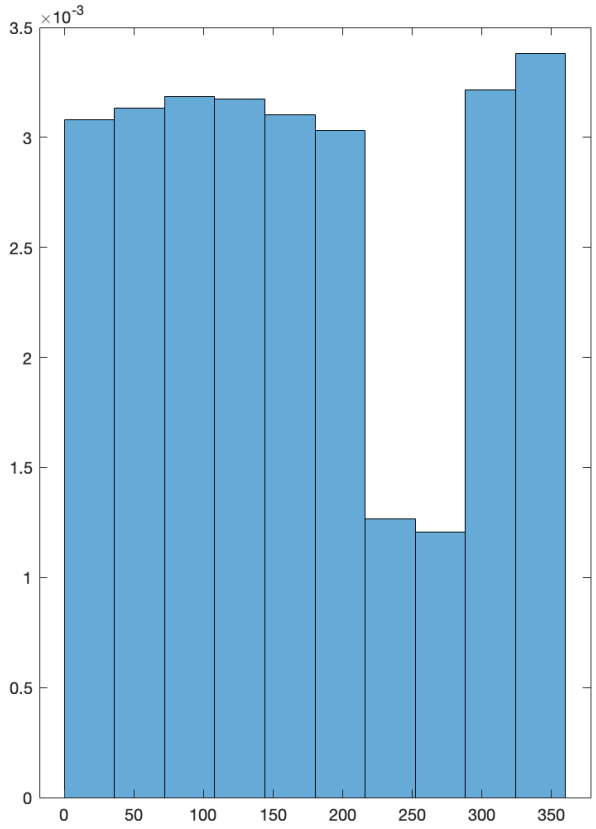

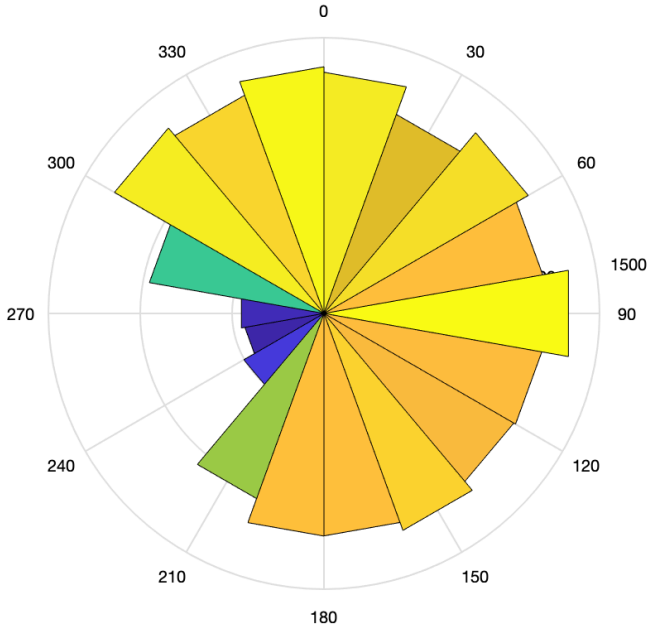

- $\bar{x} = 171$ (degrés), $s = 108$ (degrés)
- $q_{0.05} = 16$, $q_{0.25} = 80$, $q_{0.5} = 159$, $q_{0.75} = 279$, $q_{0.95} = 345$

Exemple - direction du vent

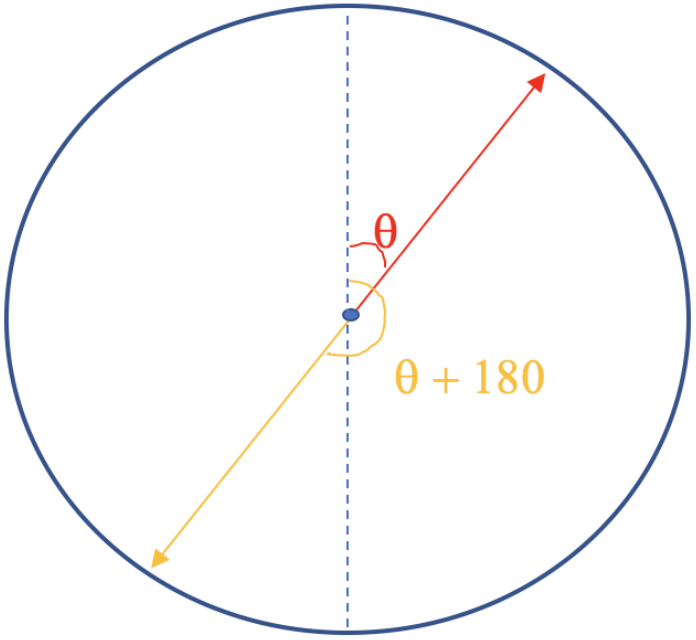

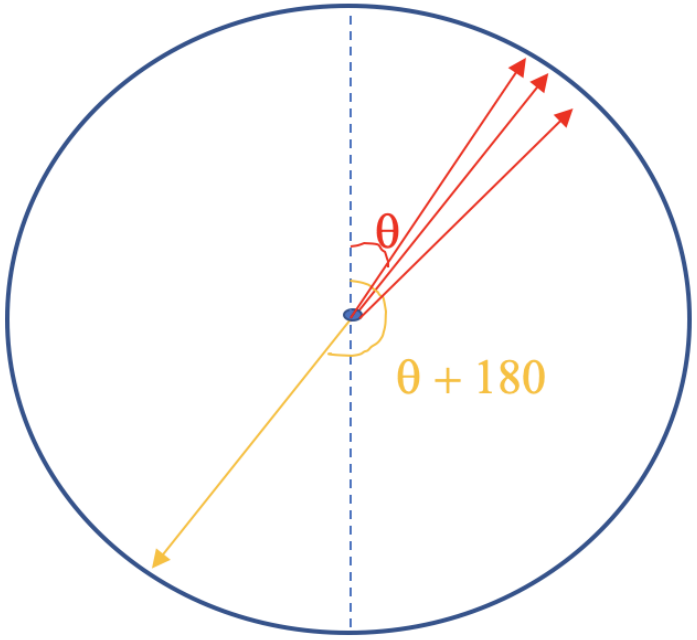

Calcul du vecteur moyen (centre de gravité du nuage de points) puis obtention de l'angle. Sur les données du vent on obtient 67 degrés.

Statistiques descriptive pour un couple de variables aléatoires

Statistiques descriptive pour un couple de variables aléatoires

On s'intéresse à la dépendance au sein du couple (X_1, X_2) à partir d'un échantillon de n observations.

- Tracer la relation entre les deux => idées de la dépendance du support
- Tracer des distributions conditionnelles
- Calcul du coefficient de corrélation (attention : il s'agit d'une dépendance linéaire)
- Test d'indépendance (exemple test du χ^2)

Statistiques descriptive pour un couple de variables aléatoires

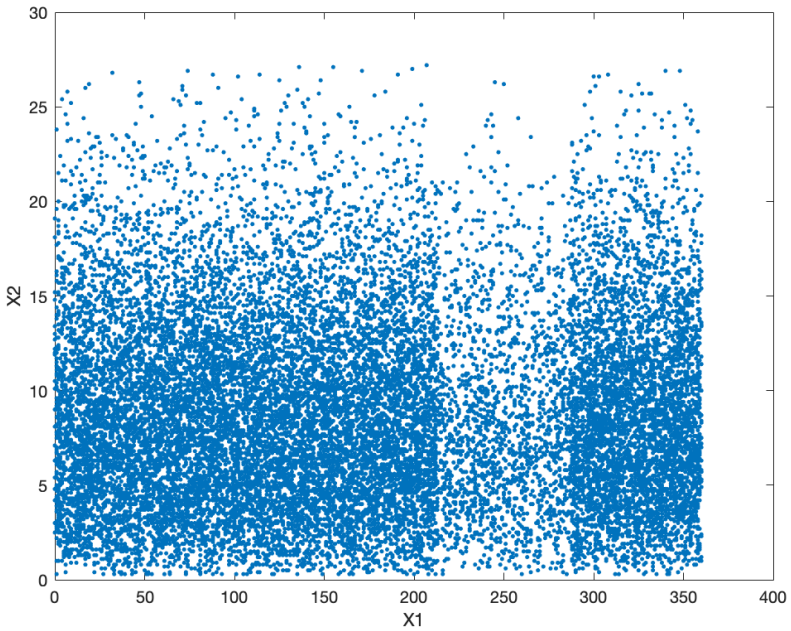

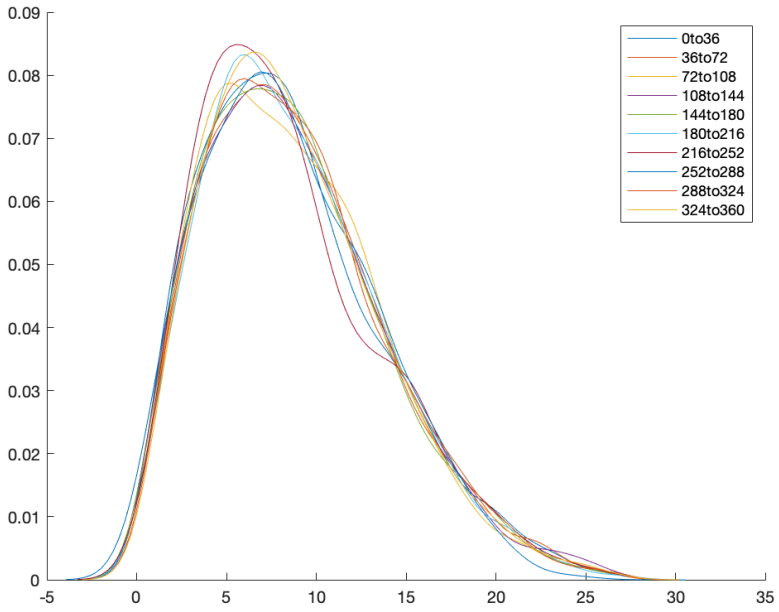

Statistique inférentielle

Objectif : ajuster une loi **paramétrique** connue sur les données

Méthodologie :

- Proposer une loi à partir de la statistique descriptive
- Estimer les paramètres de la loi
- Tester l'adéquation

Intérêt : simuler autant de données que nécessaire.

Statistique inférentielle

Objectif : ajuster une loi **paramétrique** connue sur les données

Méthodologie :

- Proposer une loi à partir de la statistique descriptive
- **Estimer les paramètres de la loi**
- Tester l'adéquation

Intérêt : simuler autant de données que nécessaire.

La méthode des moments

La méthode des moments

On confond les moments empiriques et les moments théoriques.
Exemple : si $X \sim LN(m, \sigma^2)$ alors $\mathbb{E}(X) = exp\left(m + \frac{\sigma^2}{2}\right)$ et $Var(X) = \left(exp(\sigma^2) - 1\right) exp\left(2m + \sigma^2\right)$.

L'objectif est donc de retrouver m et σ^2 à partir des données. En identifiant moments théoriques et moments empiriques, c'est-à-dire :

$$\begin{cases} \bar{x} \approx & exp\left(m + \frac{\sigma^2}{2}\right) \\ s^2 \approx & \left(exp(\sigma^2) - 1\right) exp\left(2m + \sigma^2\right) \end{cases}$$

on obtient

$$\begin{cases} \hat{\sigma}^2 & = ln\left(1 + \frac{s^2}{\bar{x}^2}\right) \\ \hat{m} & = ln(\bar{x}) - \frac{1}{2}\sigma^2 \end{cases}$$

Exemple

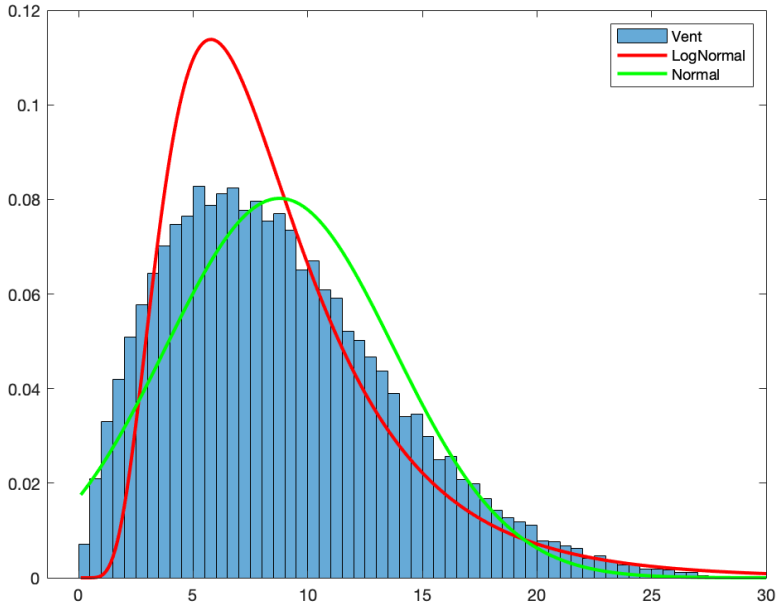

$$\hat{m} = 0.2786$$
$$\hat{\sigma}^2 = 2.0324$$

Il faut ensuite tester l'adéquation à la loi.

Modèle - validation de modèle

Modélisation des incertitudes

Propagation des incertitudes

Extensions

Propagation des incertitudes

Variables d'environnement
$X_1, \ldots, X_p$

Variables de dimensionnement
$V_1, \ldots, V_m$

Variables de calibration
$\eta_1, \ldots, \eta_q$

φ

Variable d'intérêt Y

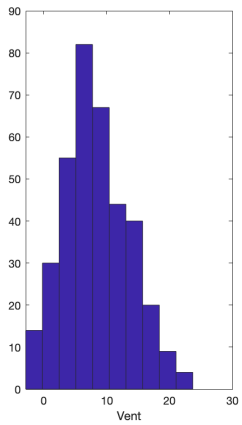

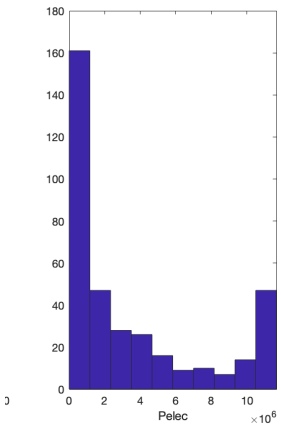

Propagation des incertitudes

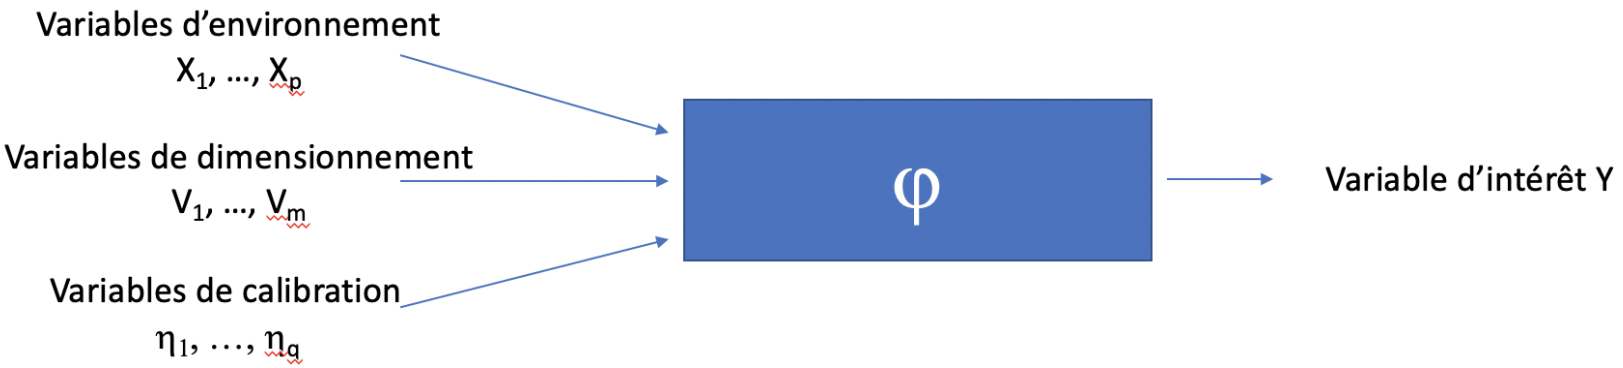

- Vaut-il mieux $\varphi(\mathbb{E}(\mathbf{X}))$ ou $\mathbb{E}(\varphi(\mathbf{X}))$?

Propagation des incertitudes

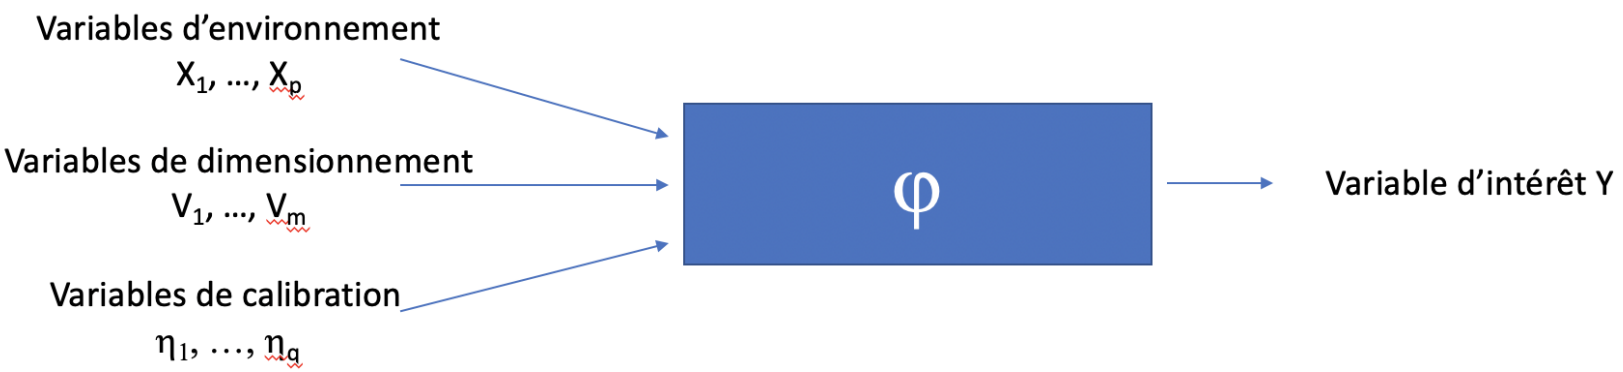

- Vaut-il mieux $\varphi(\mathbb{E}(\mathbf{X}))$ ou $\mathbb{E}(\varphi(\mathbf{X}))$?
- Plus généralement c'est toute la distribution de $Y = \varphi(\mathbf{X})$ qui nous intéresse (espérance, variance, quantiles, cdf, pdf).

Calcul de $\mathbb{E}(\varphi(\mathbf{X}))$

- Cas linéaire
  Si $\varphi(\mathbf{X}) = a\mathbf{X} + b$ alors $\mathbb{E}(\varphi(\mathbf{X})) = a\mathbb{E}(\mathbf{X}) + b$

Calcul de $\mathbb{E}(\varphi(\mathbf{X}))$

- Cas linéaire
  Si $\varphi(\mathbf{X}) = a\mathbf{X} + b$ alors $\mathbb{E}(\varphi(\mathbf{X})) = a\mathbb{E}(\mathbf{X}) + b$

- Cas non linéaire
  Si $\mu_{\mathbf{X}}$ et φ sont connus analytiquement,

Calcul de $\mathbb{E}(\varphi(\mathbf{X}))$

- Cas linéaire
  Si $\varphi(\mathbf{X}) = a\mathbf{X} + b$ alors $\mathbb{E}(\varphi(\mathbf{X})) = a\mathbb{E}(\mathbf{X}) + b$

- Cas non linéaire
  Si $\mu_{\mathbf{X}}$ et φ sont connus analytiquement, on applique la formule de transfert :

$$\mathbb{E}(\varphi(\mathbf{X})) = \int \varphi(\mathbf{x}) d\mu_{\mathbf{X}}(\mathbf{x})$$

Calcul de $\mathbb{E}(\varphi(\mathbf{X}))$

- Cas linéaire
  Si $\varphi(\mathbf{X}) = a\mathbf{X} + b$ alors $\mathbb{E}(\varphi(\mathbf{X})) = a\mathbb{E}(\mathbf{X}) + b$

- Cas non linéaire
  Si $\mu_{\mathbf{X}}$ et φ sont connus analytiquement, on applique la formule de transfert :

$$\mathbb{E}(\varphi(\mathbf{X})) = \int \varphi(\mathbf{x}) d\mu_{\mathbf{X}}(\mathbf{x})$$

- Cas non analytique
  - $\mu_{\mathbf{X}}$ n'est pas connue, seules des réalisations sont accessibles
  - et/ou φ n'a pas une expression analytique simple (boîte noire)

Calcul de $\mathbb{E}(\varphi(\mathbf{X}))$

- Cas linéaire
  Si $\varphi(\mathbf{X}) = a\mathbf{X} + b$ alors $\mathbb{E}(\varphi(\mathbf{X})) = a\mathbb{E}(\mathbf{X}) + b$

- Cas non linéaire
  Si $\mu_{\mathbf{X}}$ et φ sont connus analytiquement, on applique la formule de transfert :

$$\mathbb{E}(\varphi(\mathbf{X})) = \int \varphi(\mathbf{x}) d\mu_{\mathbf{X}}(\mathbf{x})$$

- Cas non analytique
  - $\mu_{\mathbf{X}}$ n'est pas connue, seules des réalisations sont accessibles
  - et/ou φ n'a pas une expression analytique simple (boîte noire)

  => on utilise la méthode de Monte Carlo.

La méthode de Monte Carlo

Soit $(\mathbf{X}_1, ..., \mathbf{X}_n)$ un échantillon de la v.a. $\mathbf{X}$ de loi $\mu_{\mathbf{X}}$.

- Calcul de $\mathbb{E}(\varphi(\mathbf{X}))$

$$\mathbb{E}(\varphi(\mathbf{X})) \approx \frac{1}{n} \sum_{i=1}^{n} \varphi(\mathbf{X}_i)$$

La méthode de Monte Carlo

Soit $(\mathbf{X}_1, ..., \mathbf{X}_n)$ un échantillon de la v.a. $\mathbf{X}$ de loi $\mu_{\mathbf{X}}$.

- Calcul de $\mathbb{E}(\varphi(\mathbf{X}))$

$$\mathbb{E}(\varphi(\mathbf{X})) \approx \frac{1}{n}\sum_{i=1}^{n} \varphi(\mathbf{X}_i)$$

- Calcul de $F_{\varphi(\mathbf{X})}(\mathbf{y}) = P(\varphi(\mathbf{X}) \leq \mathbf{y})$

$$P(\varphi(\mathbf{X}) \leq \mathbf{y}) \approx \frac{1}{n}\sum_{i=1}^{n} \mathbf{1}_{\varphi(\mathbf{X}_i)\leq \mathbf{y}}$$

Exemple

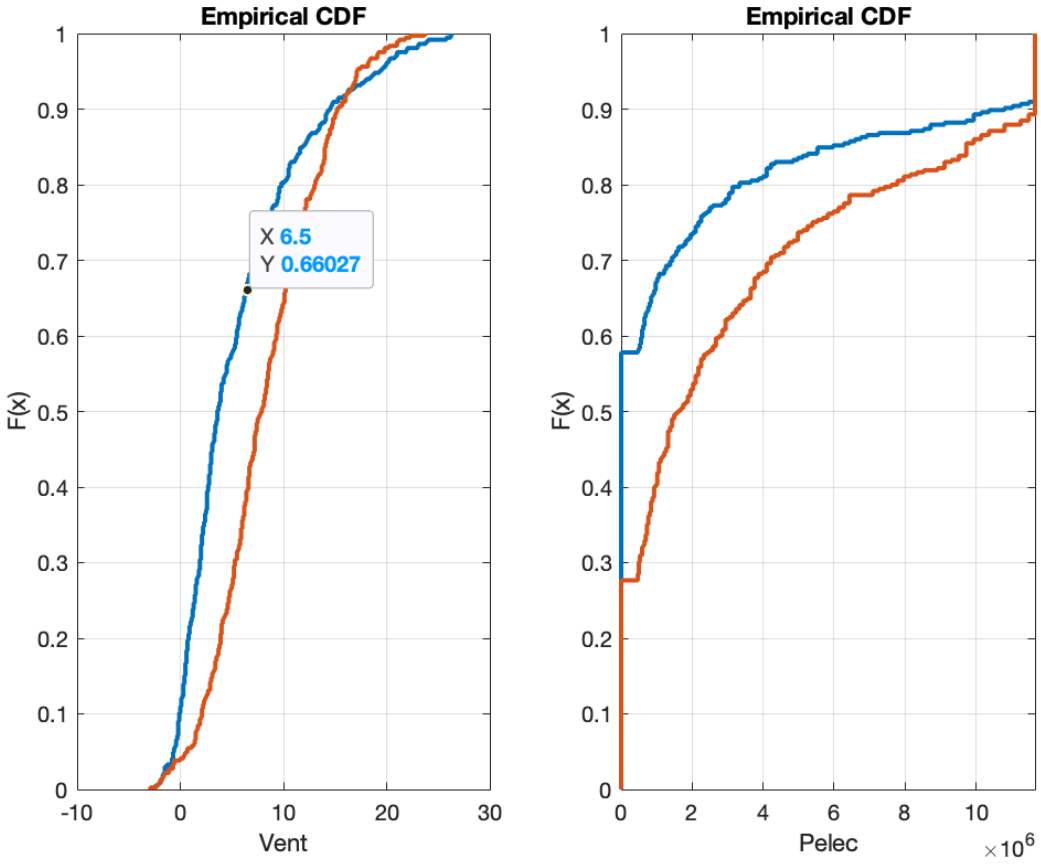

$\overline{Vitesse_vent} = 8.4(m/s)$ et $\overline{Pelec} = 3.5 \times 10^6$

$\overline{Vitesse_vent} = 5.7(m/s)$ et $\overline{Pelec} = 2.1 \times 10^6$

Modèle - validation de modèle

Modélisation des incertitudes

Propagation des incertitudes

Extensions

Evolution en fonction du temps de 1995 à 2015 (21 ans)

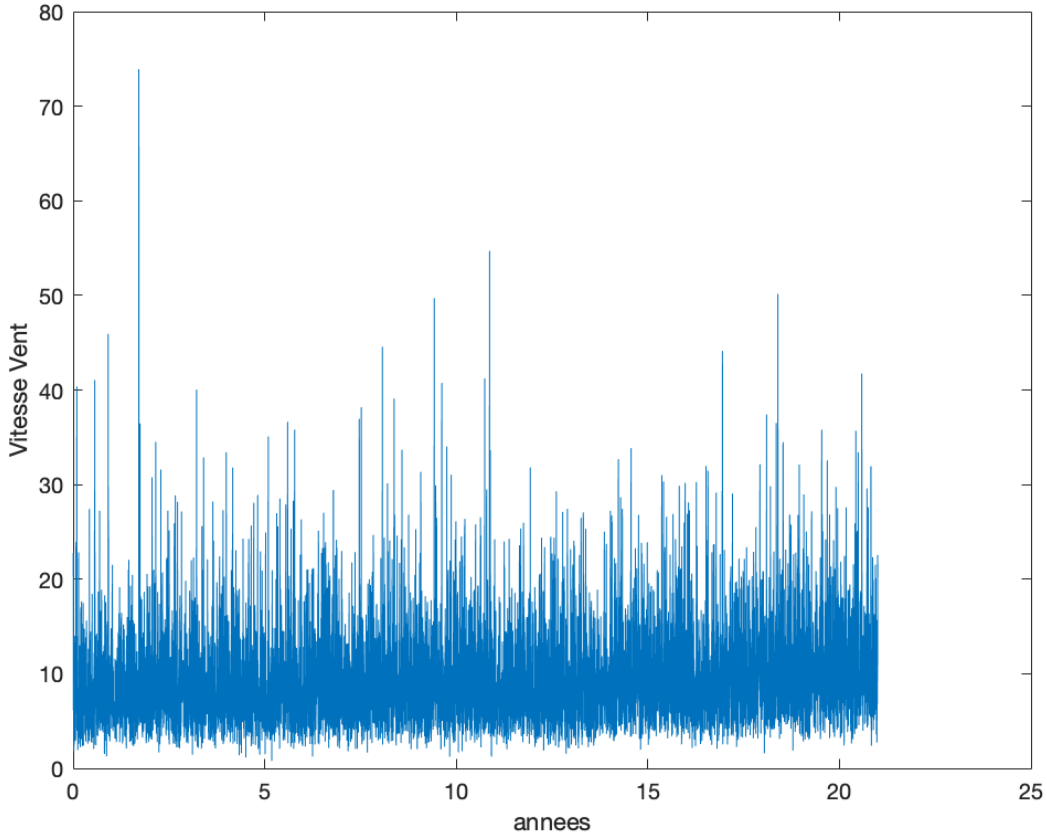

Histogrammes 1995, 2000, 2005, 2010, 2015

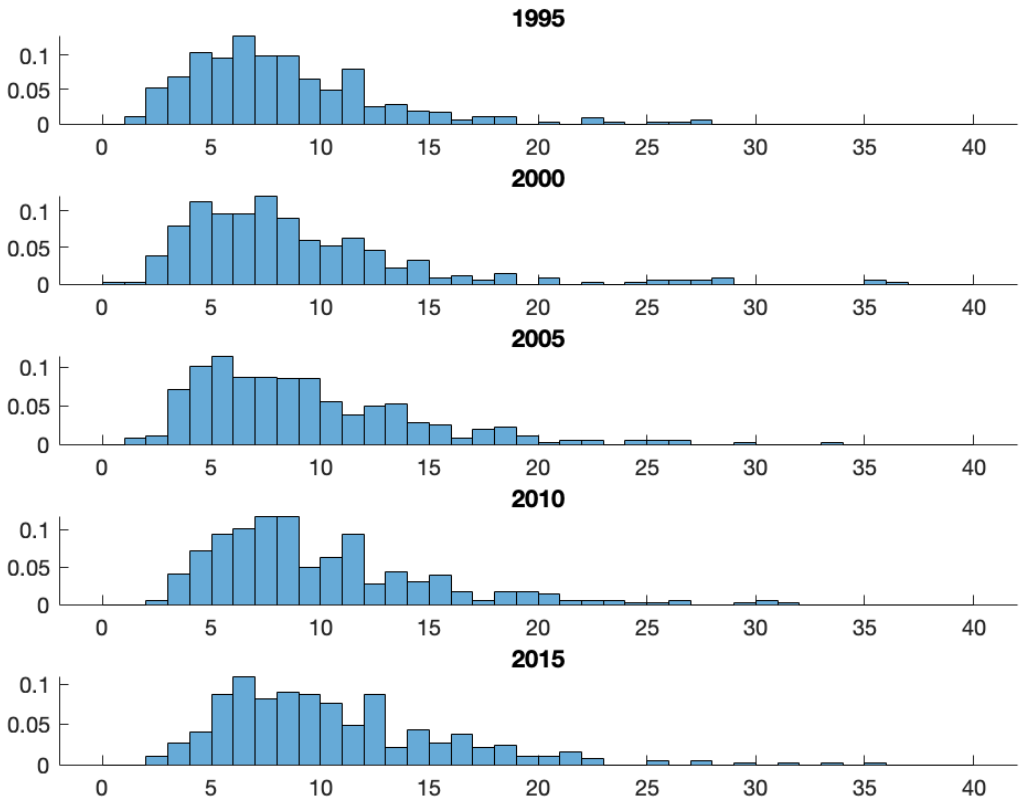

Histogrammes 1995, 2000, 2005, 2010, 2015

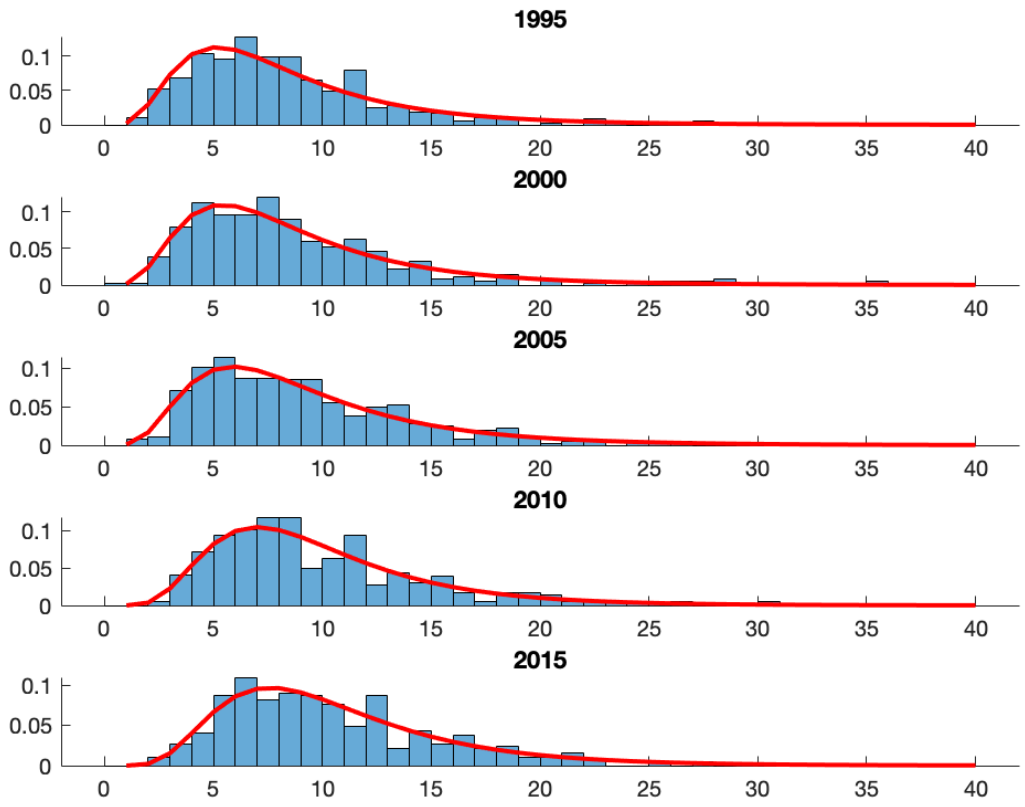

$$\mathbf{X}_t \sim LN(m_t, \sigma_t^2)$$

Modèle des paramètres en fonction du temps

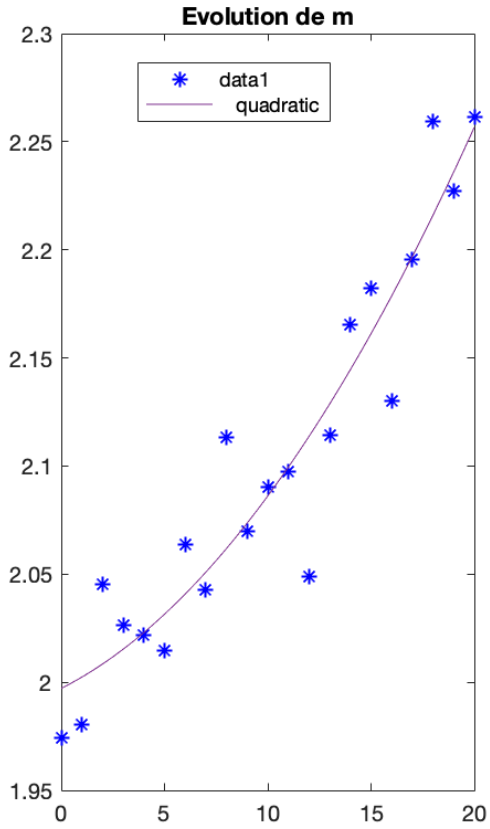

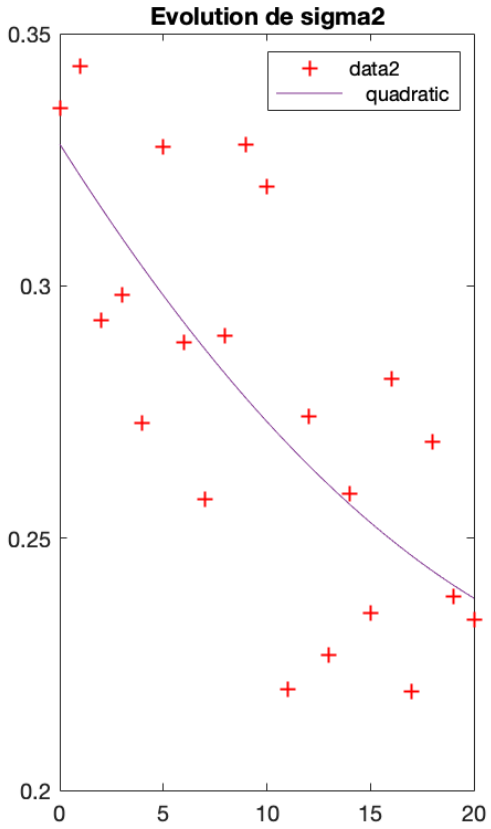

Attention : il faut quantifier les incertitudes de prédiction quand on travaille en extrapolation ...

Evolution en fonction de l'espace

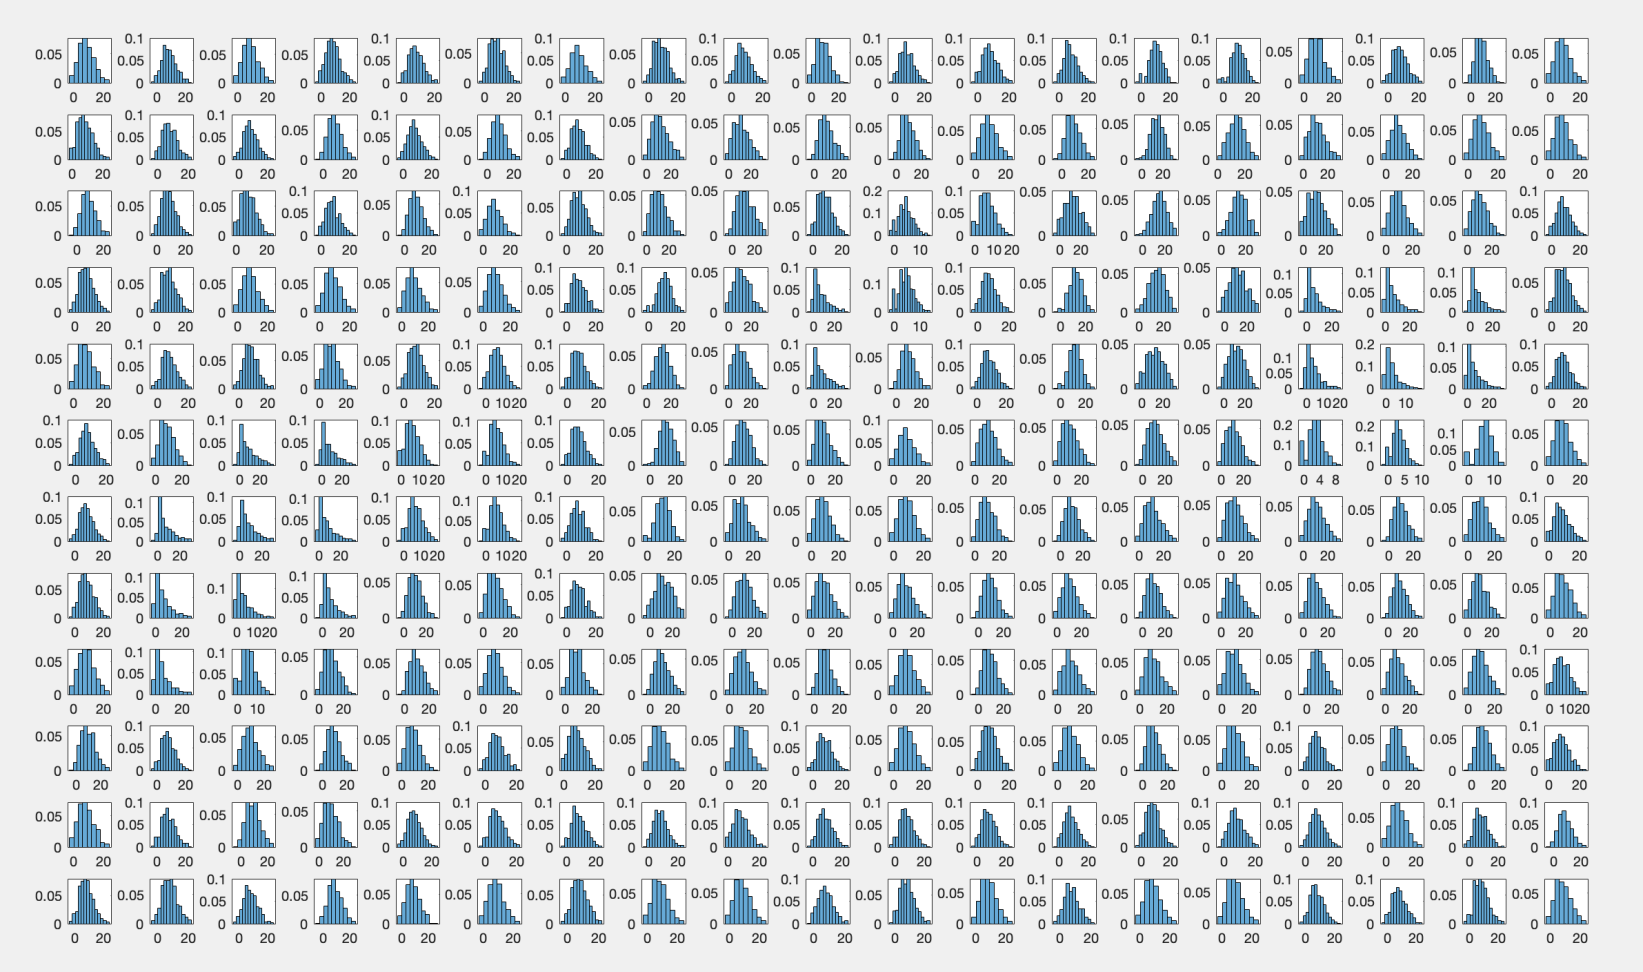

Evolution en fonction de l'espace

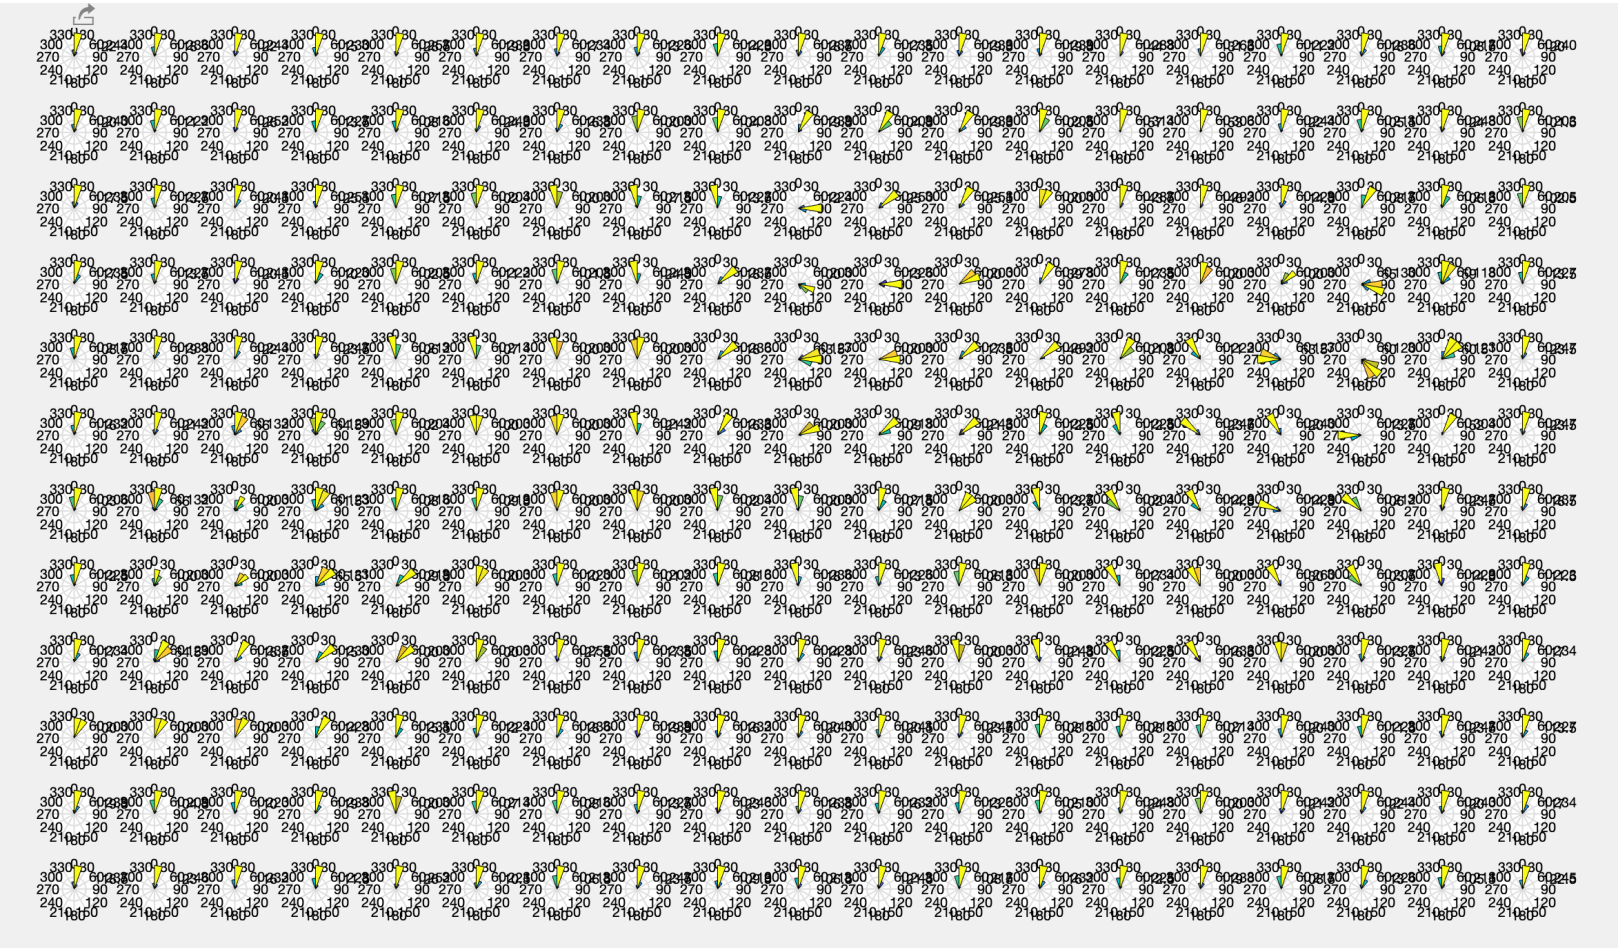

Questions ?

36, avenue Guy de Collongue 69130 Écully - France
+33 (0)4 72 18 60 00